

Bài 9: Mạng hồi quy

Nội dung



- 1. Bài toán dự đoán chuỗi
- 2. Mạng hồi quy thông thường
- 3. Lan truyền ngược theo thời gian (BPTT)
- 4. Mạng LSTM và GRU
- 5. Một số áp dụng



Bài toán dự đoán chuỗi



- Trước giờ, ta chỉ tập trung vào vấn đề dự đoán với đầu vào và đầu ra kích thước cố định
- Chuyện gì sẽ xảy ra nếu đầu vào và đầu ra là một chuỗi có kích thước thay đổi?

Phân lớp văn bản

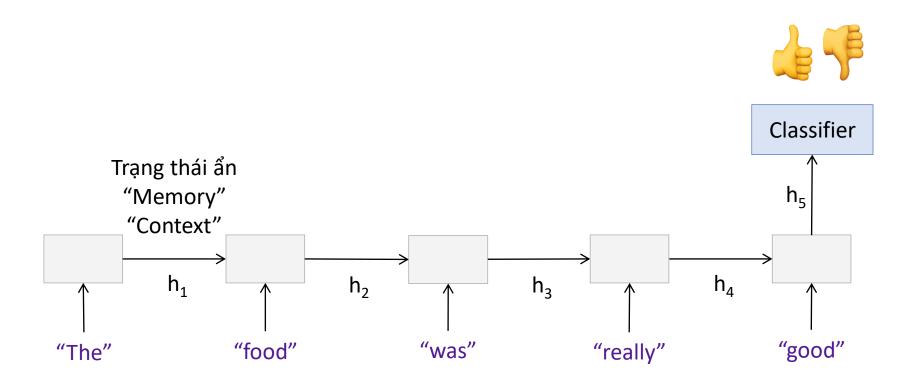


- Phân loại sắc thái (sentiment): phân loại bình luận một nhà hàng hay một bộ phim hay một sản phẩm là tích cực hay tiêu cực
 - "The food was really good" "Thức ăn rất ngon"
 - "Máy hút bụi bị hỏng trong vòng hai tuần"
 - "Bộ phim có những phần buồn tẻ, nhưng tổng thể là rất đáng xem"
- Cần dùng đặc trưng gì và mô hình phân loại gì để giải quyết bài toán này?

Phân loại sắc thái



"The food was really good"



Recurrent Neural Network (RNN)

Mô hình ngôn ngữ

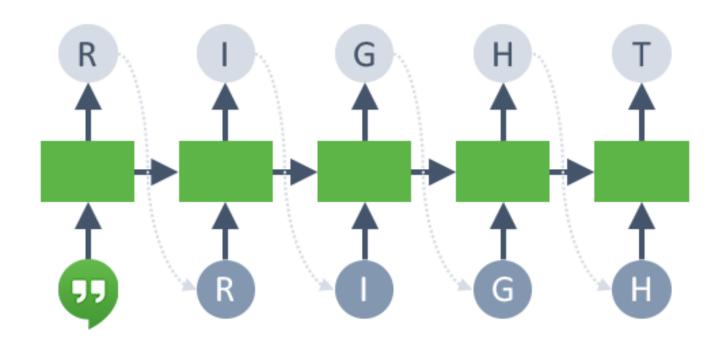




Mô hình ngôn ngữ

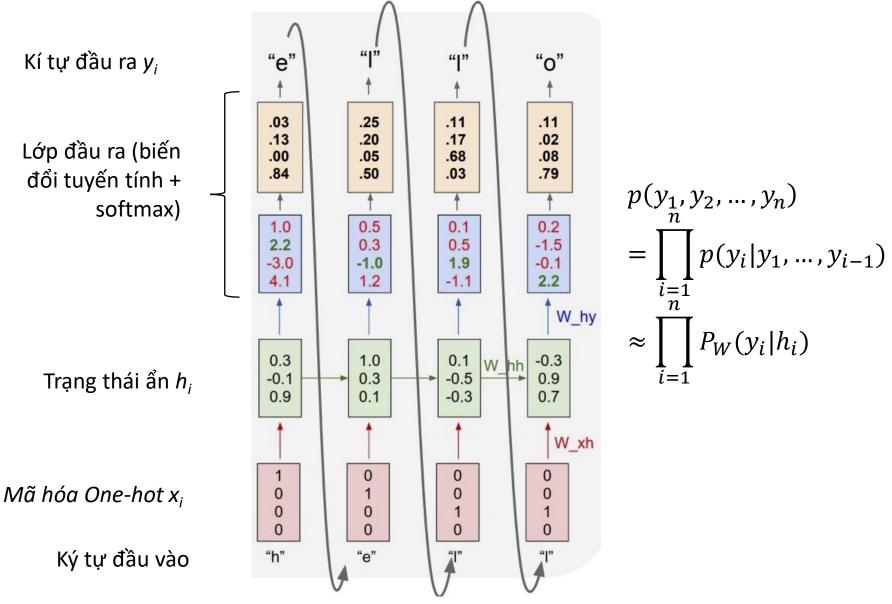


Character RNN



Character RNN





SangDV

Sinh mô tả bức ảnh



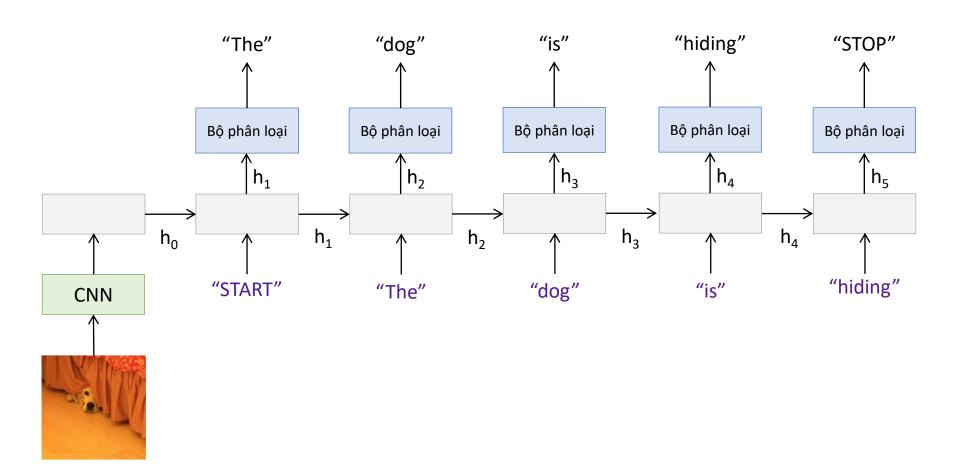
 Cho một bức ảnh, cần sinh ra một câu mô tả nội dung bức ảnh



"The dog is hiding"

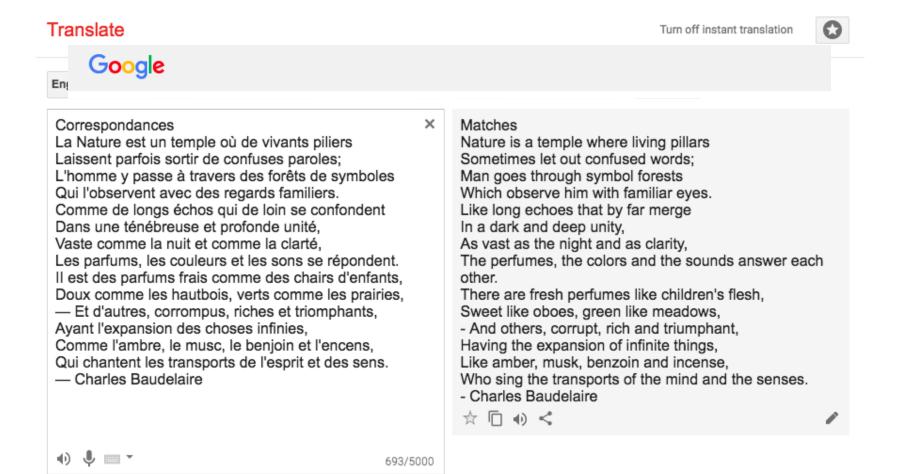
Sinh mô tả bức ảnh





Dịch máy



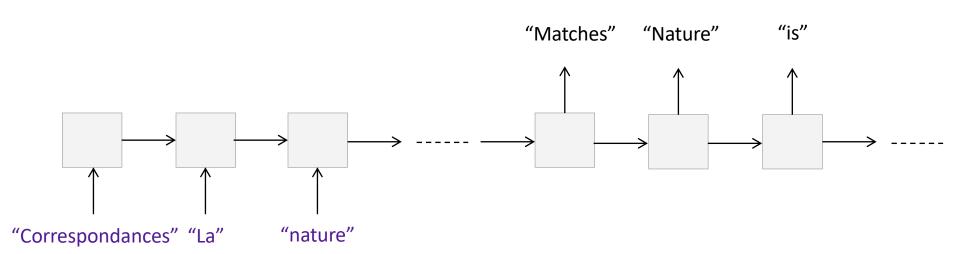


https://translate.google.com/

Dịch máy



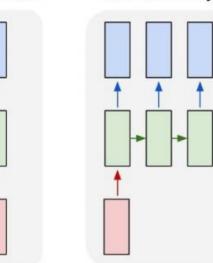
 Nhiều đầu vào – nhiều đầu ra (hay còn gọi là sequence to sequence)



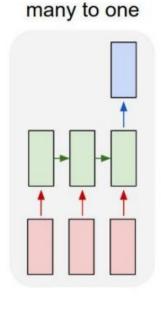
Tổng hợp các loại dự đoán



one to one



one to many



many to many

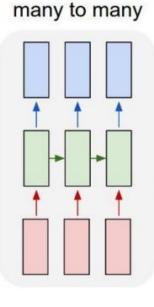


Phân lớp ảnh

Sinh mô tả ảnh

Phân loại sắc thái câu

Dịch máy

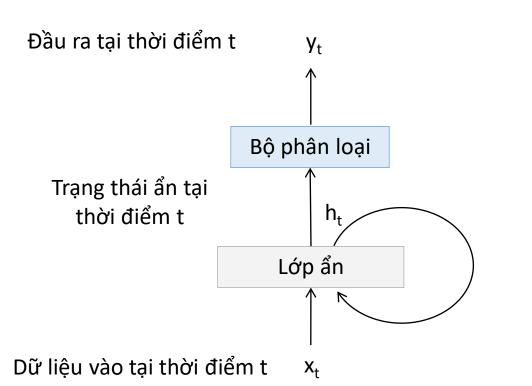


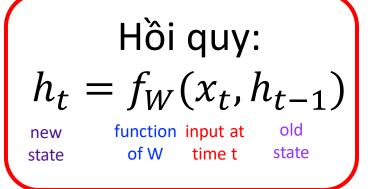
Phân loại video mức frame



Mạng hồi quy Recurrent Neural Network (RNN)

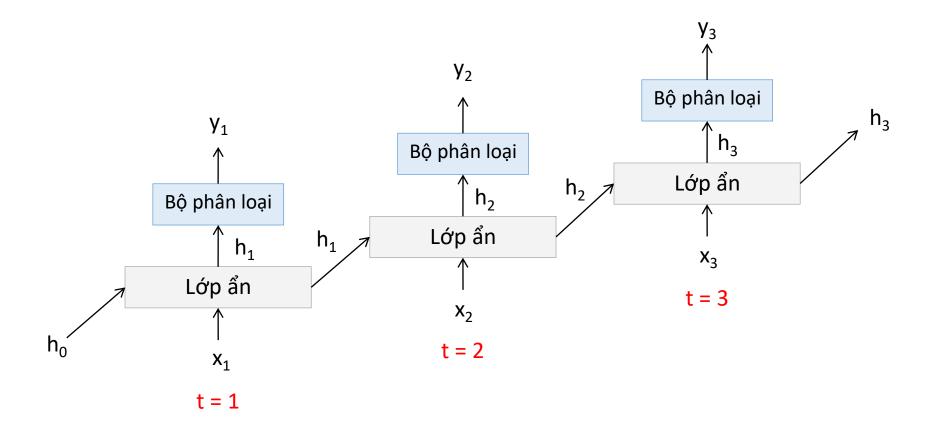




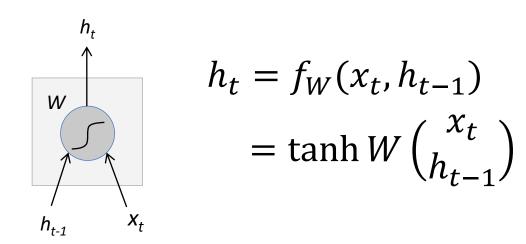


Duỗi (unroll) RNN



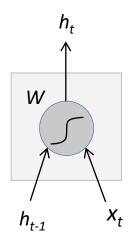






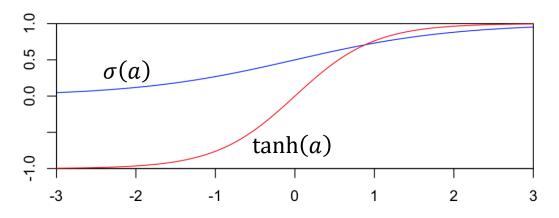
J. Elman, Finding structure in time, Cognitive science 14(2), pp. 179–211, 1990





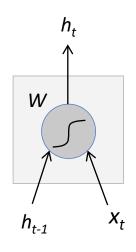
$$h_t = f_W(x_t, h_{t-1})$$

$$= \tanh W {x_t \choose h_{t-1}}$$



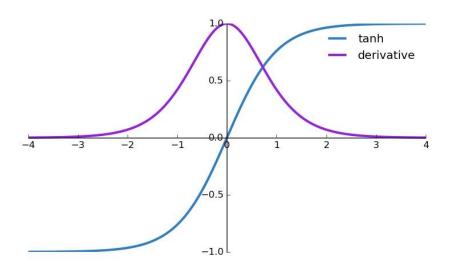
$$\tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}$$
$$= 2\sigma(2a) - 1$$





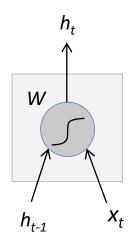
$$h_t = f_W(x_t, h_{t-1})$$

$$= \tanh W {x_t \choose h_{t-1}}$$



$$\frac{d}{da}\tanh(a) = 1 - \tanh^2(a)$$

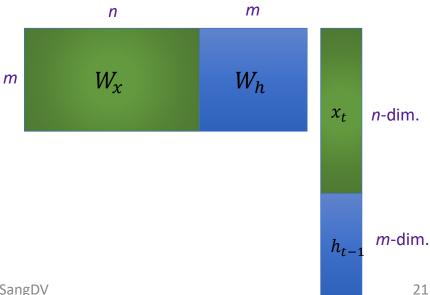




$$h_t = f_W(x_t, h_{t-1})$$

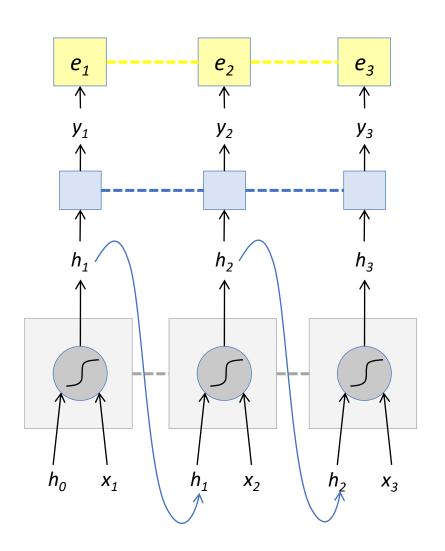
$$= \tanh W {x_t \choose h_{t-1}}$$

$$= \tanh(W_x x_t + W_h h_{t-1})$$



RNN Forward Pass



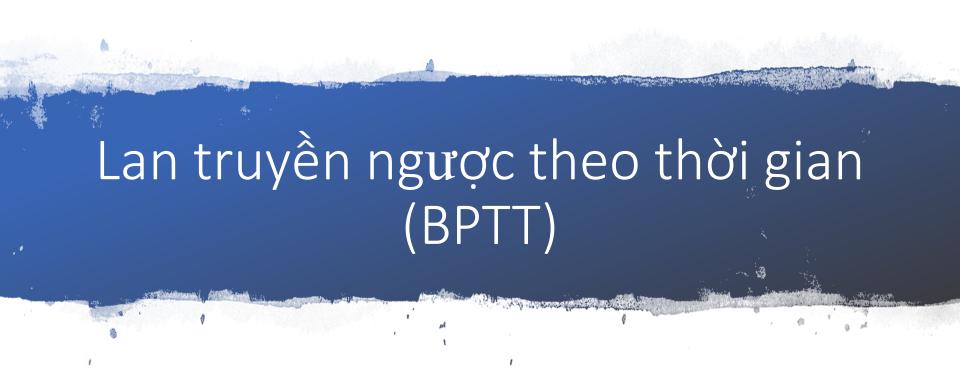


$$e_t = -\log(y_t(GT_t))$$

$$y_t = \operatorname{softmax}(W_y h_t)$$

$$h_t = \tanh W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

---- Dùng chung trọng số (shared weights)



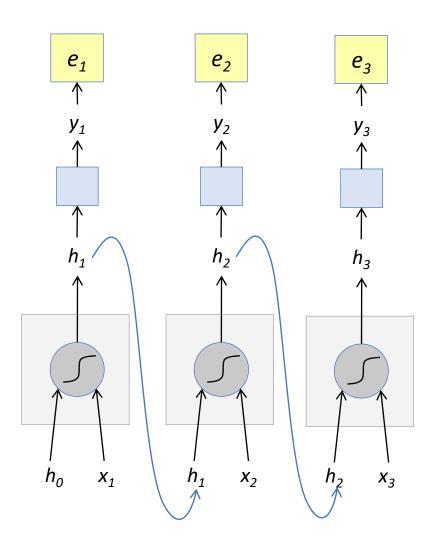
Lan truyền ngược theo thời gian (BPTT)



- Đây là phương pháp thông dụng nhất để huấn luyện RNNs
- Mạng sau khi duỗi được xem như một mạng nơ-ron feed-forward lớn nhận dữ liệu đầu vào là cả chuỗi dữ liệu
- Gradient đối với một trọng số mạng RNN được tính tại mỗi bản sao của nó trong mạng duỗi (unfolded network), sau đó được cộng lại (hoặc tính trung bình) và được sử dụng để cập nhật trọng số mạng.

Tính toán tiến (forward pass) mạng RNN duỗi





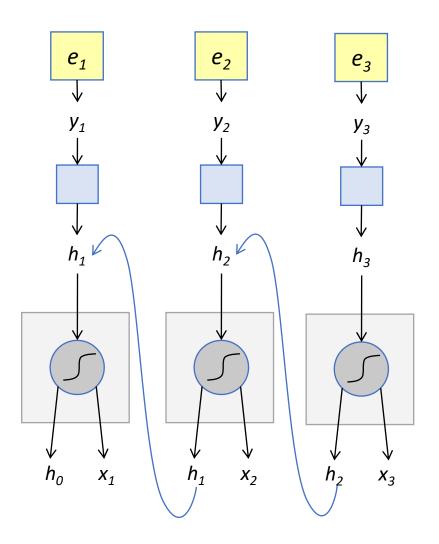
$$e_t = -\log(y_t(GT_t))$$

$$y_t = \operatorname{softmax}(W_y h_t)$$

$$h_t = \tanh W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

Tính toán tiến (forward pass) mạng RNN duỗi





$$e_t = -\log(y_t(GT_t))$$

$$y_t = \operatorname{softmax}(W_y h_t)$$

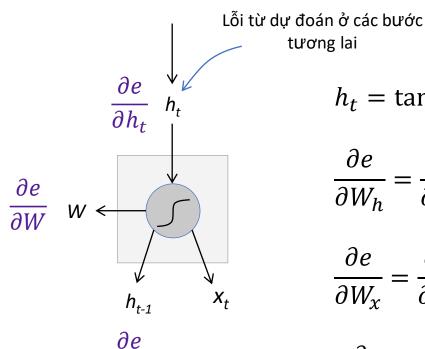
$$h_t = \tanh W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

Lan truyền ngược mạng RNN

tương lai



Lỗi từ y_t



 ∂h_{t-1}

Lan truyền ngược tới các bước sớm hơn

$$h_t = \tanh(W_x x_t + W_h h_{t-1})$$

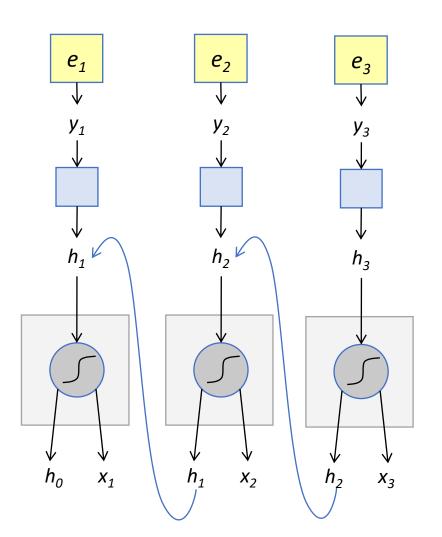
$$\frac{\partial e}{\partial W_h} = \frac{\partial e}{\partial h_t} \odot \left(1 - \tanh^2(W_x x_t + W_h h_{t-1})\right) h_{t-1}^T$$

$$\frac{\partial e}{\partial W_x} = \frac{\partial e}{\partial h_t} \odot \left(1 - \tanh^2(W_x x_t + W_h h_{t-1})\right) x_t^T$$

$$\frac{\partial e}{\partial h_{t-1}} = W_h^T \left(1 - \tanh^2 (W_{x} x_t + W_h h_{t-1}) \right) \odot \frac{\partial e}{\partial h_t}$$

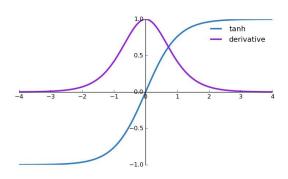
Lan truyền ngược mạng RNN





$$\frac{\partial e}{\partial h_{t-1}} = W_h^T \left(1 - \tanh^2(W_x x_t + W_h h_{t-1}) \right) \odot \frac{\partial e}{\partial h_t}$$

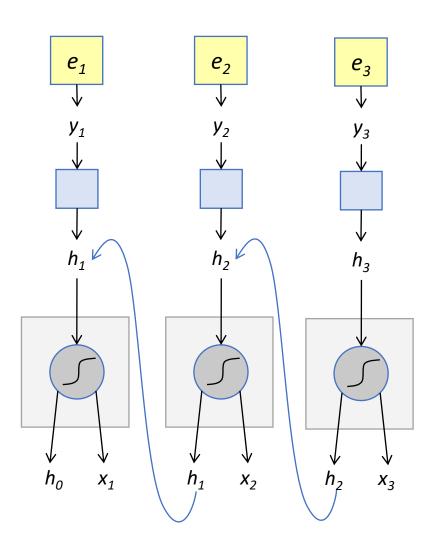
Giá trị hàm tanh lớn sẽ tương ứng với gradient nhỏ (vùng bão hòa)



Xét
$$\frac{\partial e_n}{\partial h_k}$$
 với $k \ll n$

Lan truyền ngược mạng RNN





$$\frac{\partial e}{\partial h_{t-1}} = W_h^T \left(1 - \tanh^2(W_x x_t + W_h h_{t-1}) \right) \odot \frac{\partial e}{\partial h_t}$$

Gradient sẽ triệt tiêu nếu giá trị riêng lớn nhất của W_h nhỏ hơn 1

Xét
$$\frac{\partial e_n}{\partial h_k}$$
 với $k \ll n$

Chi tiết xem tại khóa cs224n



Recall:

$$oldsymbol{h}^{(t)} = \sigma \left(oldsymbol{W}_h oldsymbol{h}^{(t-1)} + oldsymbol{W}_x oldsymbol{x}^{(t)} + oldsymbol{b}_1
ight)$$

• What if σ were the identity function, $\sigma(x) = x$?

$$rac{\partial m{h}^{(t)}}{\partial m{h}^{(t-1)}} = \mathrm{diag}\left(\sigma'\left(m{W}_hm{h}^{(t-1)} + m{W}_xm{x}^{(t)} + m{b}_1
ight)\right)m{W}_h \qquad ext{(chain rule)}$$

$$= m{I} \ m{W}_h = m{W}_h$$

• Consider the gradient of the loss $J^{(i)}(heta)$ on step i, with respect to the hidden state $m{h}^{(j)}$ on some previous step j. Let $\ell=i-j$

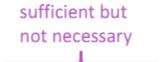
$$\begin{split} \frac{\partial J^{(i)}(\theta)}{\partial \boldsymbol{h}^{(j)}} &= \frac{\partial J^{(i)}(\theta)}{\partial \boldsymbol{h}^{(i)}} \prod_{j < t \leq i} \frac{\partial \boldsymbol{h}^{(t)}}{\partial \boldsymbol{h}^{(t-1)}} & \text{(chain rule)} \\ &= \frac{\partial J^{(i)}(\theta)}{\partial \boldsymbol{h}^{(i)}} \prod_{j < t \leq i} \boldsymbol{W}_h = \frac{\partial J^{(i)}(\theta)}{\partial \boldsymbol{h}^{(i)}} \boldsymbol{W}_h^{\ell} & \text{(value of } \frac{\partial \boldsymbol{h}^{(t)}}{\partial \boldsymbol{h}^{(t-1)}} \text{)} \end{split}$$

If W_h is "small", then this term gets exponentially problematic as ℓ becomes large

Chi tiết xem tại khóa cs224n



• What's wrong with W_h^{ℓ} ?



Consider if the eigenvalues of W_h are all less than 1:

$$\lambda_1, \lambda_2, \dots, \lambda_n < 1$$

 $\boldsymbol{q}_1, \boldsymbol{q}_2, \dots, \boldsymbol{q}_n$ (eigenvectors)

• We can write $rac{\partial J^{(i)}(heta)}{\partial m{h}^{(i)}}$ $m{W}_h^\ell$ using the eigenvectors of $m{W}_h$ as a basis:

$$\frac{\partial J^{(i)}(\theta)}{\partial \boldsymbol{h}^{(i)}} \boldsymbol{W}_h^{\ell} = \sum_{i=1}^n c_i \lambda_i^{\ell} \boldsymbol{q}_i \approx \boldsymbol{0} \; (\text{for large } \ell)$$
 Approaches 0 as ℓ grows

so gradient vanishes

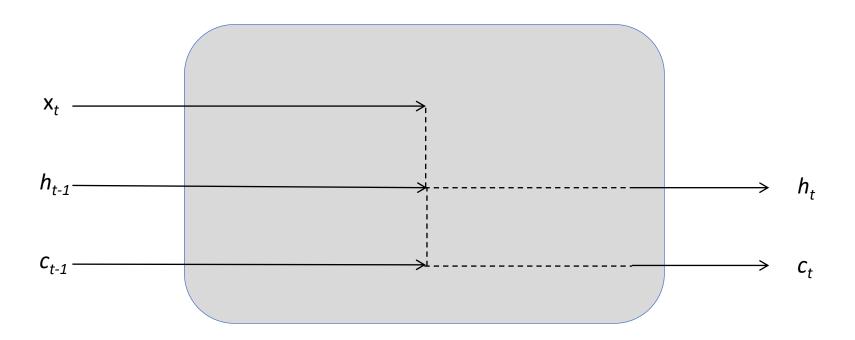
- What about nonlinear activations σ (i.e., what we use?)
 - Pretty much the same thing, except the proof requires $\lambda_i < \gamma$ for some γ dependent on dimensionality and σ



Long Short-Term Memory (LSTM)



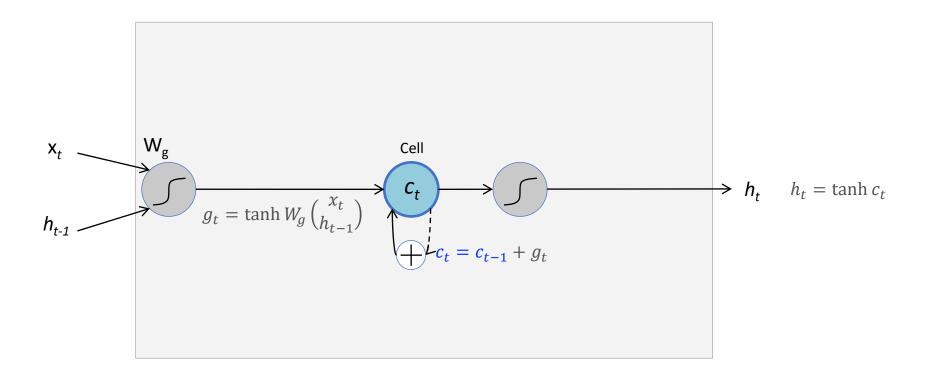
 Sử dụng thêm "cell" có bộ nhớ để tránh hiện tượng triệt tiêu gradient



S. Hochreiter and J. Schmidhuber, Long short-term memory, Neural Computation 9 (8), pp. 1735–1780, 1997

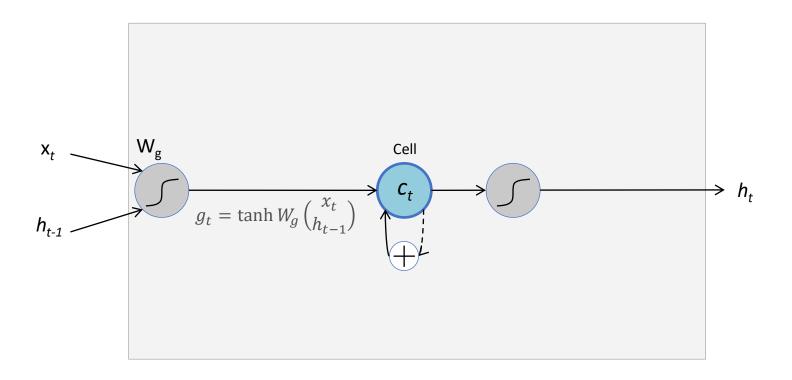
LSTM Cell





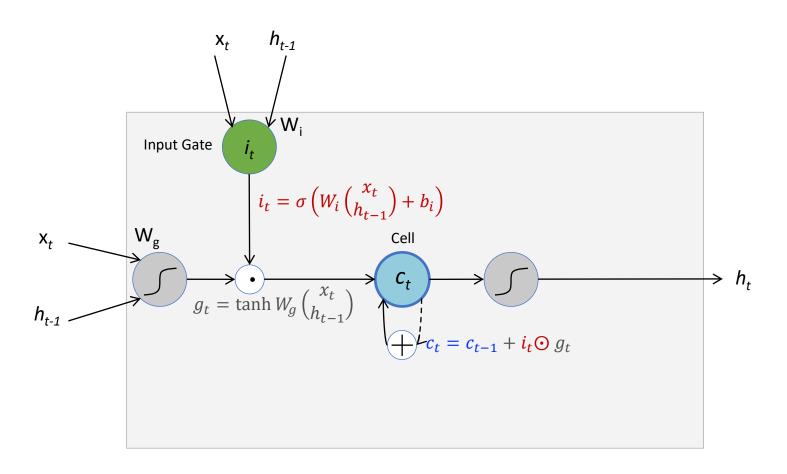
LSTM Cell





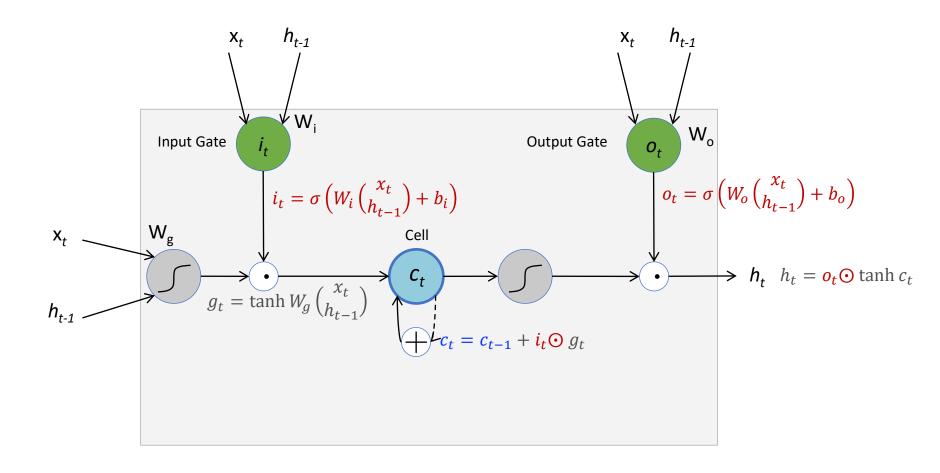
LSTM Cell





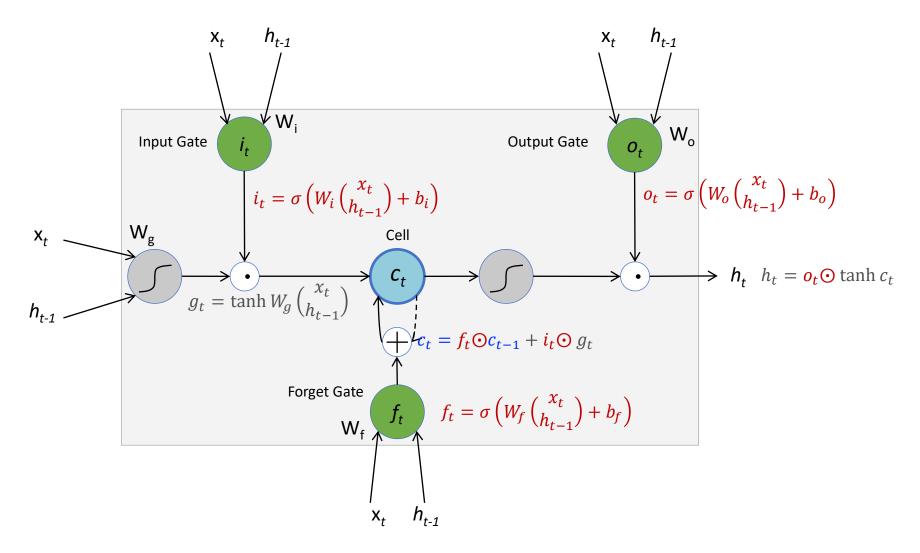
LSTM Cell





LSTM Cell



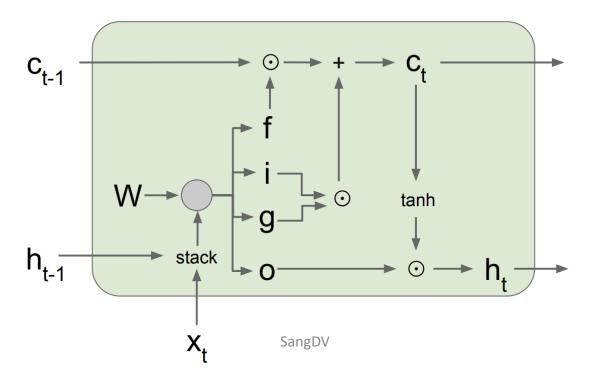


LSTM Forward Pass Summary



$$\bullet \begin{pmatrix} g_t \\ i_t \\ f_t \\ o_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \\ \sigma \end{pmatrix} \begin{pmatrix} W_g \\ W_i \\ W_f \\ W_o \end{pmatrix} \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

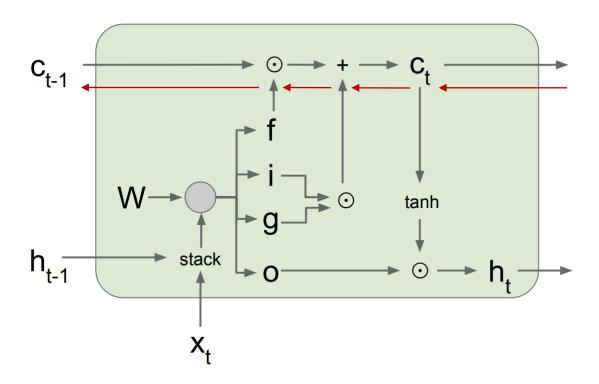
- $c_t = f_t \odot c_{t-1} + i_t \odot g_t$
- $h_t = o_t \odot \tanh c_t$



Lan truyền ngược LSTM



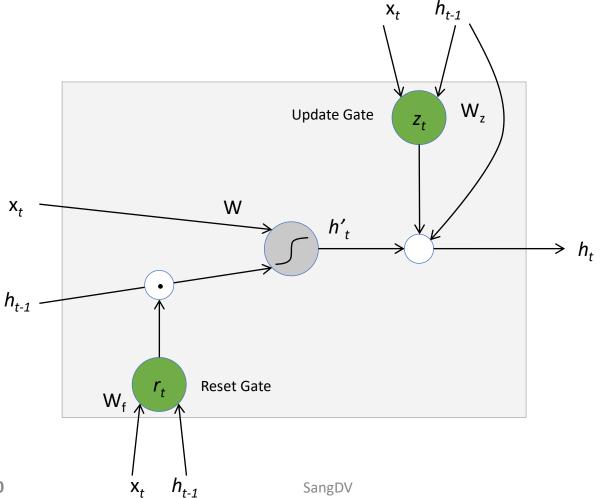
• Luồng gradient từ c_t tới c_{t-1} chỉ lan truyền ngược qua phép cộng và nhân từng phần tử, không đi qua phép nhân ma trận và hàm tanh



For complete details: Illustrated LSTM Forward and Backward Pass

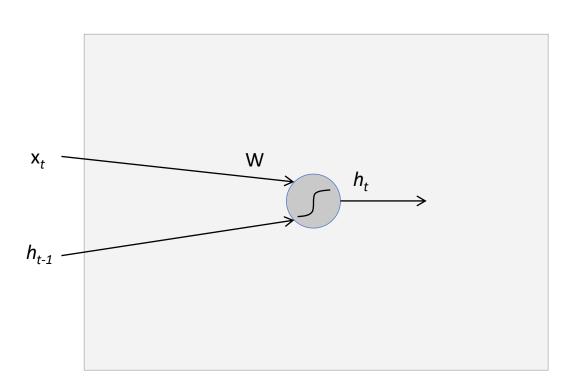


- · Không dùng "cell state" riêng biệt, ghép chung với hidden state
- Kết hợp cổng "forget" và "output" thành cổng "update"



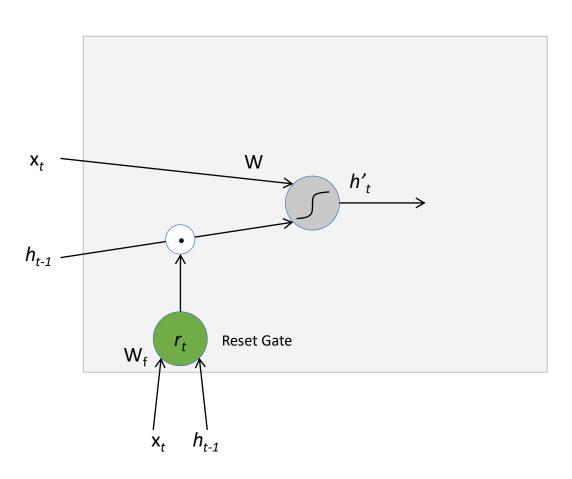
04/05/2020 42





$$h_t = \tanh W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

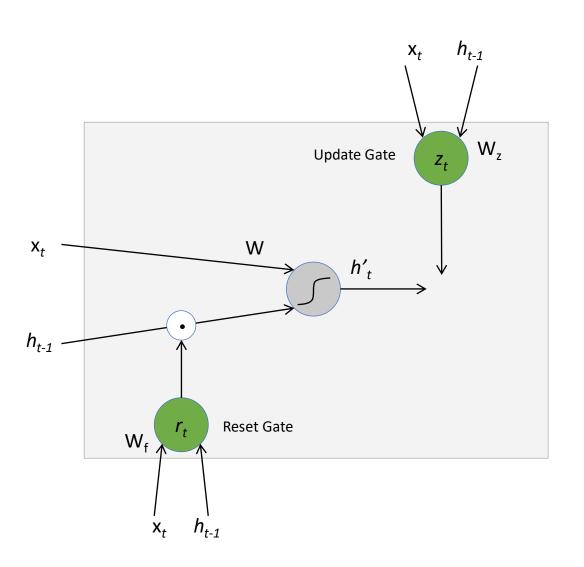




$$r_t = \sigma \left(W_r \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_t \right)$$

$$h'_t = \tanh W \begin{pmatrix} x_t \\ r_t \odot h_{t-1} \end{pmatrix}$$



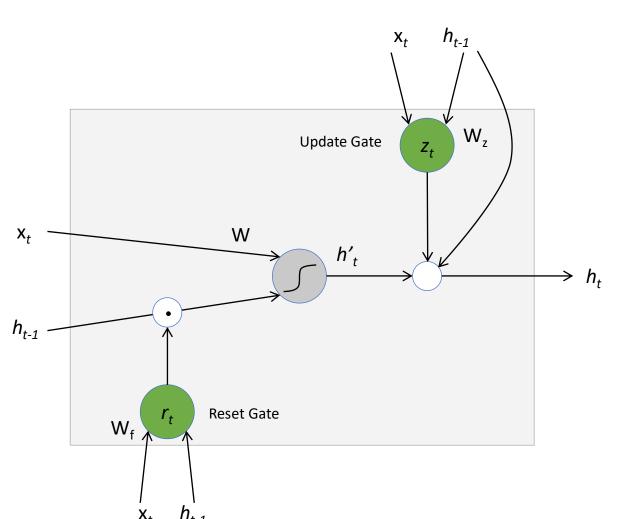


$$r_{t} = \sigma \left(W_{r} \begin{pmatrix} x_{t} \\ h_{t-1} \end{pmatrix} + b_{t} \right)$$

$$h'_t = \tanh W \begin{pmatrix} x_t \\ r_t \odot h_{t-1} \end{pmatrix}$$

$$z_t = \sigma \left(W_z \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_z \right)$$





$$r_{t} = \sigma \left(W_{r} \begin{pmatrix} x_{t} \\ h_{t-1} \end{pmatrix} + b_{t} \right)$$

$$h'_t = \tanh W \begin{pmatrix} x_t \\ r_t \odot h_{t-1} \end{pmatrix}$$

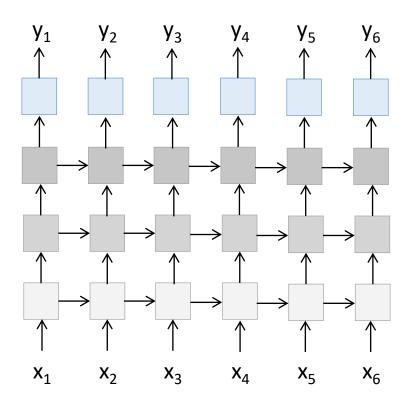
$$z_{t} = \sigma \left(W_{z} \begin{pmatrix} x_{t} \\ h_{t-1} \end{pmatrix} + b_{z} \right)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot h_t'$$

RNNs nhiều lớp



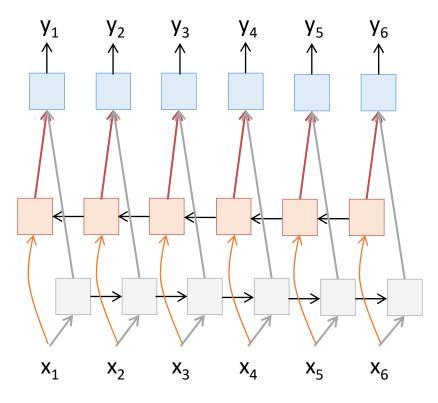
• Có thể thiết kế RNNs với nhiều lớp ẩn



RNNs hai chiều



 RNNs có thể xử lý chuỗi đầu vào theo chiều ngược vào chiều xuôi

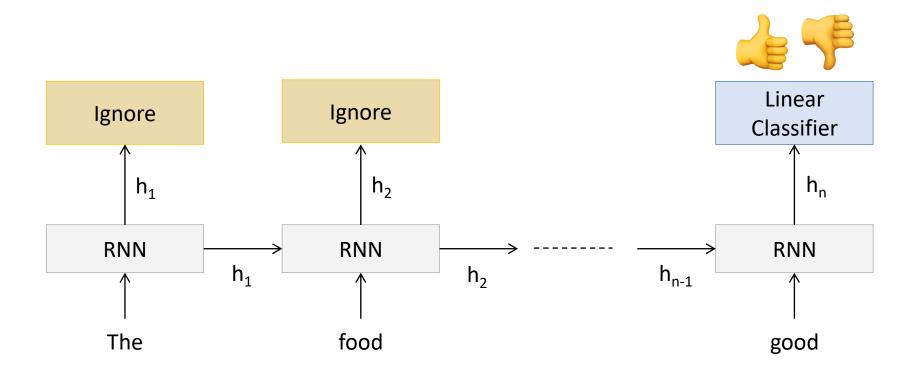


Phổ biến trong nhận dạng âm thanh



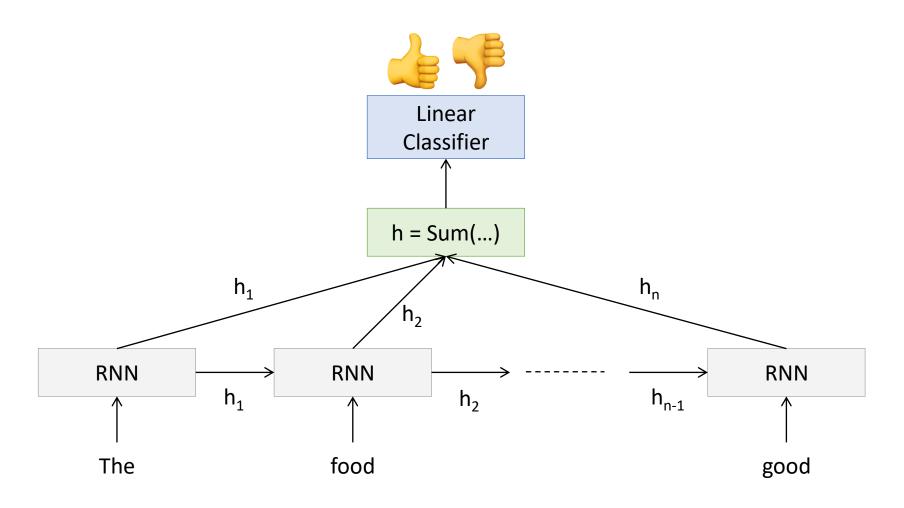
Phân loại chuỗi





Phân loại chuỗi

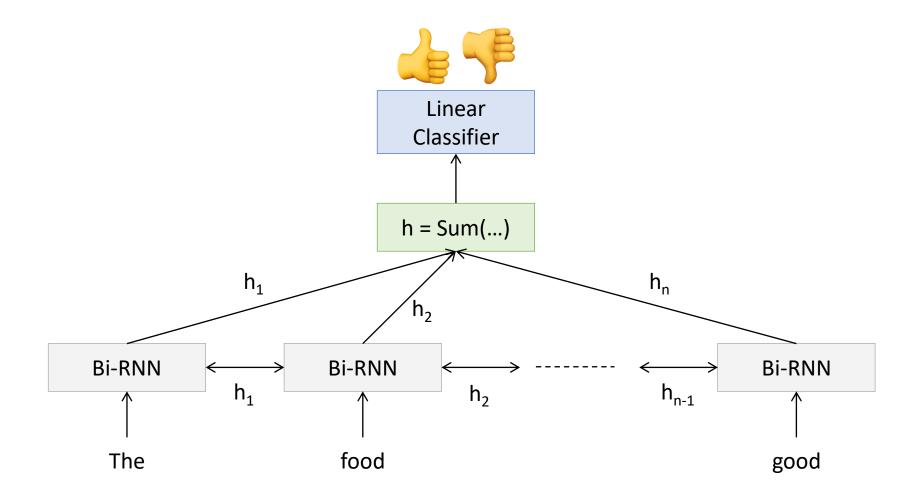




http://deeplearning.net/tutorial/lstm.html

Phân loại chuỗi





Character RNN



100th iteration

tyntd-iafhatawiaoihrdemot lytdws e ,tfti, astai f ogoh eoase rrranbyne 'nhthnee e plia tklrgd t o idoe ns,smtt h ne etie h,hregtrs nigtike,aoaenns lng

train more

300th iteration

"Tmont thithey" fomesscerliund
Keushey. Thom here
sheulke, anmerenith ol sivh I lalterthend Bleipile shuwy fil on aseterlome
coaniogennc Phe lism thond hon at. MeiDimorotion in ther thize."

train more

700th iteration

Aftair fall unsuch that the hall for Prince Velzonski's that me of her hearly, and behs to so arwage fiving were to it beloge, pavu say falling misfort how, and Gogition is so overelical and ofter.

train more

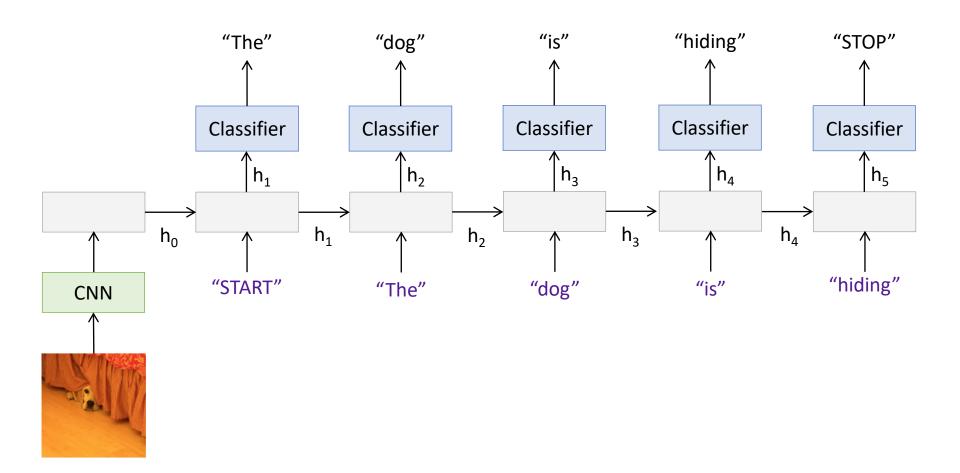
2000th iteration

"Why do what that day," replied Natasha, and wishing to himself the fact the princess, Princess Mary was easier, fed in had oftened him. Pierre aking his soul came to the packs and drove up his father-in-law women.

http://karpathy.github.io/2015/05/21/rnn-effectiveness/

Image Caption Generation





Sinh mô tả ảnh



A person riding a motorcycle on a dirt road.



A group of young people



A herd of elephants walking across a dry grass field.



Two dogs play in the grass.



Two hockey players are fighting over the puck.



A close up of a cat laying on a couch.



A skateboarder does a trick on a ramp.



A little girl in a pink hat is



A red motorcycle parked on the



A dog is jumping to catch a



A refrigerator filled with lots of food and drinks.



A yellow school bus parked



Describes without errors

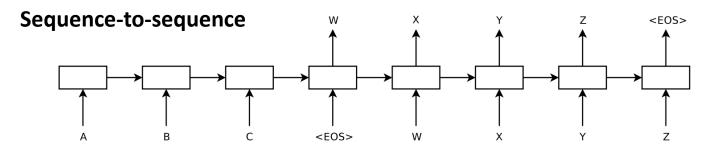
Describes with minor errors

Somewhat related to the image

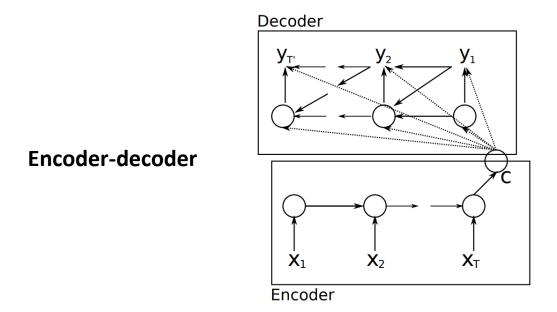
Unrelated to the image

Dịch máy





I. Sutskever, O. Vinyals, Q. Le, <u>Sequence to Sequence Learning with Neural Networks</u>, NIPS 2014



K. Cho, B. Merrienboer, C. Gulcehre, F. Bougares, H. Schwenk, and Y. Bengio, <u>Learning phrase</u> representations using RNN encoder-decoder for statistical machine translation, ACL 2014

Tài liệu tham khảo



1. Khóa cs231n của Stanford:

http://cs231n.stanford.edu

2. Khóa cs244n của Stanford:

http://web.stanford.edu/class/cs224n/slides/cs224n-2020-lecture06-rnnlm.pdf

http://web.stanford.edu/class/cs224n/slides/cs224n-2020-lecture07-fancy-rnn.pdf

3. Training RNNs:

http://www.cs.toronto.edu/~rgrosse/csc321/lec10.pdf