

# Bài 10:

## Một số ứng dụng học sâu trong xử lý ngôn ngữ tự nhiên (Phần 1)

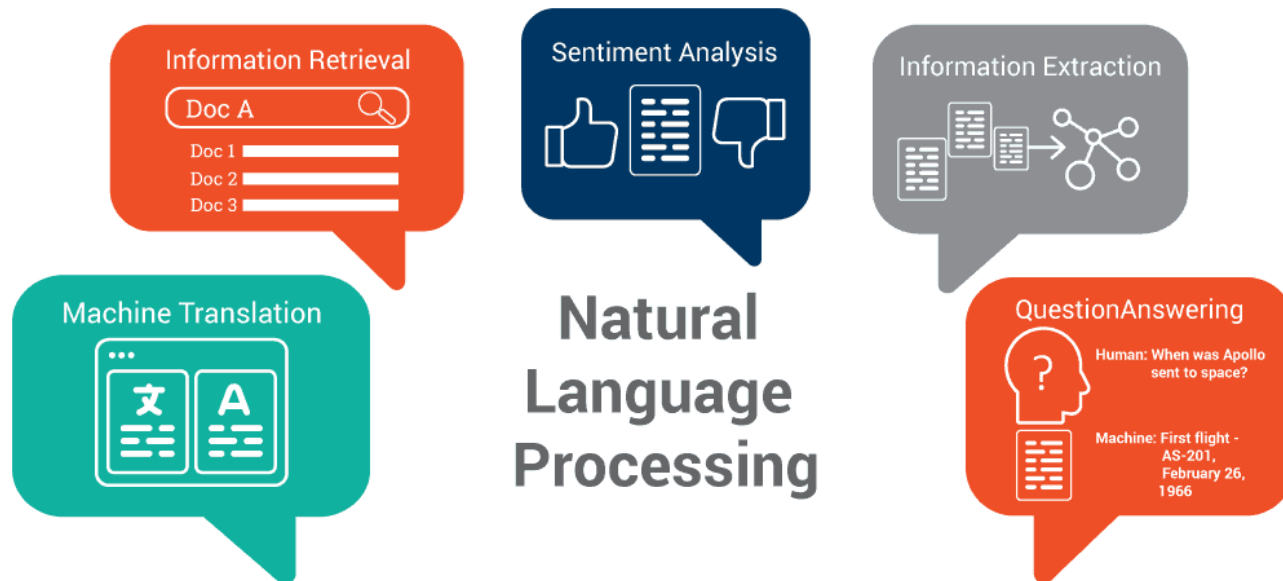
# Nội dung

1. Tổng quan về xử lý ngôn ngữ tự nhiên
2. Biểu diễn từ và văn bản
3. Thư viện Xử lý NNTN và một số mô hình huấn luyện sẵn

# Tổng quan về xử lý ngôn ngữ tự nhiên

# Thế nào là Xử lý NNTN?

- Xử lý NNTN là một nhánh của trí tuệ nhân tạo liên quan đến sự tương tác giữa máy tính và ngôn ngữ của con người.
- Mục đích của xử lý NNTN là giúp máy tính có khả năng đọc, hiểu và rút ra ý nghĩa từ ngôn ngữ của con người.



# Các mức phân tích

- **Morphology** (hình thái học): cách từ được xây dựng, các tiền tố và hậu tố của từ
- **Syntax** (cú pháp): mối liên hệ về cấu trúc ngữ pháp giữa các từ và ngữ
- **Semantics** (ngữ nghĩa): nghĩa của từ, cụm từ, và cách diễn đạt
- **Discourse** (diễn ngôn): quan hệ giữa các ý hoặc các câu
- **Pragmatic** (thực chứng): mục đích phát ngôn, cách sử dụng ngôn ngữ trong giao tiếp
- **World Knowledge** (tri thức thế giới): các tri thức về thế giới, các tri thức ngầm

# Một số ứng dụng chính của NLP

- Nhận dạng giọng nói (speech recognition)
- Khai phá văn bản
  - Phân cụm văn bản
  - Phân lớp văn bản
  - Tóm tắt văn bản
  - Mô hình hóa chủ đề (topic modelling)
  - Hỏi đáp (question answering)
- Gia sư ngôn ngữ (Language tutoring)
  - Chỉnh sửa ngữ pháp/đánh vần
- Dịch máy (machine translation)

# Dịch máy



- Google translate

Google Dịch

Văn bản Tài liệu

ANH - ĐÃ PHÁT HIỆN ANH NGA VIỆT VIẾT NGA ANH

NLP is particularly booming in the healthcare industry. This technology is improving care delivery, disease diagnosis and bringing costs down while healthcare organizations are going through a growing adoption of electronic health records. The fact that clinical documentation can be improved means that patients can be better understood and benefited through better healthcare. The goal should be to optimize their experience, and several organizations are already working on this.

NLP đặc biệt bùng nổ trong ngành chăm sóc sức khỏe. Công nghệ này đang cải thiện việc cung cấp dịch vụ chăm sóc, chẩn đoán bệnh và giảm chi phí trong khi các tổ chức chăm sóc sức khỏe đang trải qua việc áp dụng các hồ sơ sức khỏe điện tử ngày càng tăng. Thực tế là tài liệu lâm sàng có thể được cải thiện có nghĩa là bệnh nhân có thể được hiểu rõ hơn và được hưởng lợi thông qua chăm sóc sức khỏe tốt hơn. Mục tiêu nên là để tối ưu hóa trải nghiệm của họ và một số tổ chức đã làm việc về điều này.

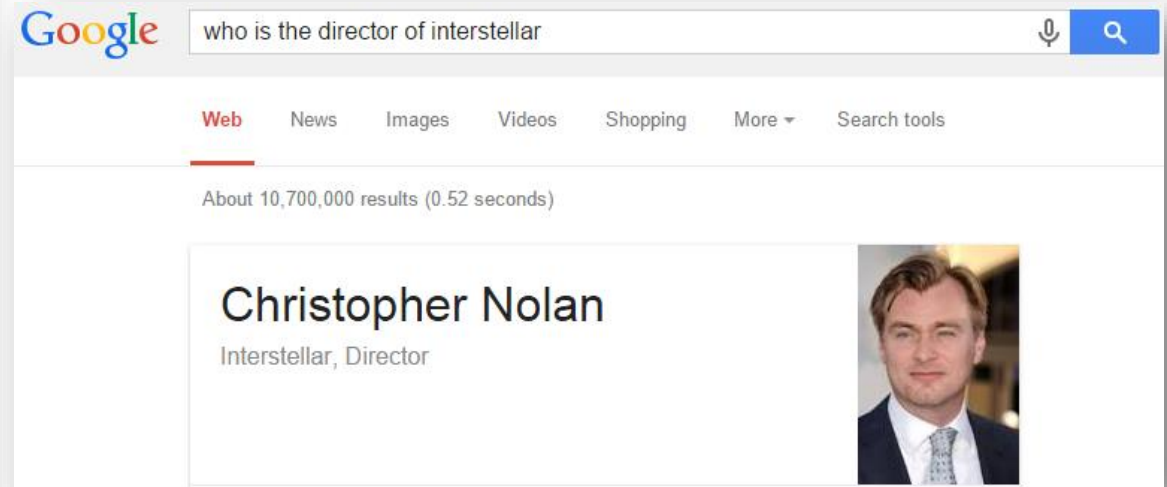
483/5000

# Các hệ thống hội thoại

- Chatbot, trợ lý ảo, hỏi đáp tự động



Apple's siri system




Google search



# Trích rút thông tin (Information extraction)

## Interstellar (2014)



**PG-13** · 2hr 49min · Science Fiction

IMDb 8.9/10 ★★★★★

Rotten Tomatoes 73% ★★★★★

In the near future around the American Midwest, Cooper an ex-science engineer and pilot, is tied to his farming land with his daughter Murph and son Tom. As devastating sandstorms ravage earth's crops, the people of Earth realize their life here ... +

[en.wikipedia.org](https://en.wikipedia.org)

Boxoffice gross: \$779 million USD

Estimated budget: \$165 million USD

Release date: Nov 05, 2014

Director: [Christopher Nolan](#)

Screenwriters: [Christopher Nolan](#) · [Jonathan Nolan](#)

Music by: [Hans Zimmer](#)

Watch movie

 [Watch trailer on YouTube](#)

Cast

[See all \(20+\)](#)



Matthew McConaughey  
Cooper



Anne Hathaway  
Brand



Jessica Chastain  
Murph



Casey Affleck



Wes Bentley  
Doyle

Google Knowledge Graph

## University of Virginia



Established	1819
Type	Public Flagship
Endowment	US\$6.4 billion <sup>[1]</sup>
Budget	US\$2.7 billion (2013— excludes capital spending)
President	Teresa A. Sullivan
Academic staff	2,102
Undergraduates	14,898 <sup>[2]</sup>
Postgraduates	6,340 <sup>[2]</sup>
Location	Charlottesville, Virginia, United States
Campus	Suburban 1,682 acres (6.81 km <sup>2</sup> )

Wiki Info Box

# Token hóa (Tokenization)

- Chia văn bản thành các từ và các câu

There was an earthquake near  
D.C. I've even felt it in  
Philadelphia, New York, etc.

There + was + an + earthquake  
+ near + D.C.

I + ve + even + felt + it + in +  
Philadelphia, + New + York, + etc.

# Part-of-Speech tagging

- Xác định từ loại của từng từ trong văn bản

A + dog + is + chasing + a + boy + on + the + playground

A	+	dog	+	is	+	chasing	+	a	+	boy	+	on	+	the	+	playground
Det		Noun		Aux		Verb		Det		Noun		Prep		Det		Noun

# Nhận dạng thực thể định danh (Named entity recognition)



- Tìm kiếm và phân loại các thành phần trong văn bản vào những loại xác định trước như là tên người, tổ chức, địa điểm, thời gian, số lượng, giá trị tiền tệ...

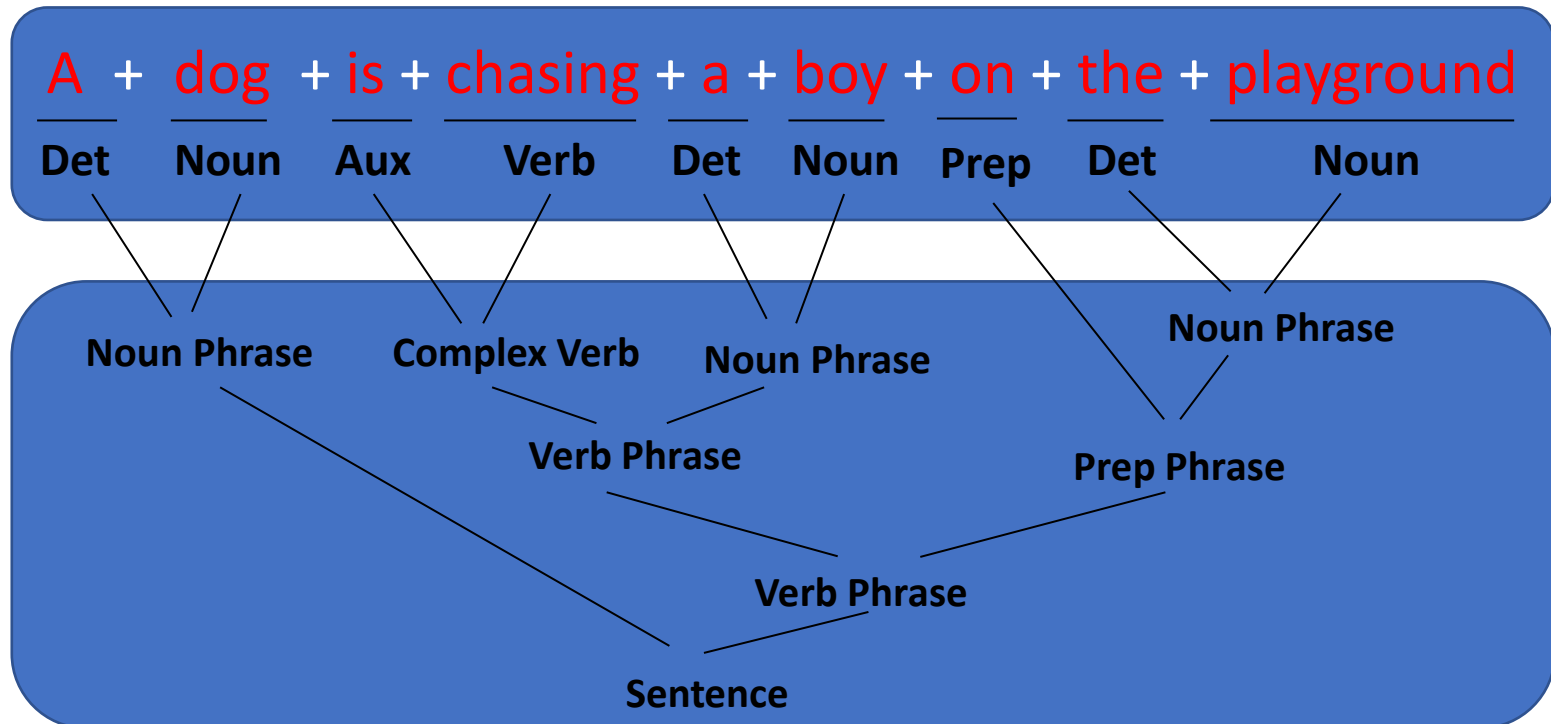
Its initial Board of Visitors included U.S. Presidents Thomas Jefferson, James Madison, and James Monroe.

Its initial **Board of Visitors** included **U.S.** Presidents Thomas Jefferson, James Madison, and James Monroe.

**Organization**, **Location**, **Person**

# Syntactic parsing

- Phân tích ngữ pháp của một câu cho trước theo các quy tắc ngữ pháp



# Trích rút quan hệ (Relation extraction)

- Xác định quan hệ giữa các thực thể
  - Phân tích ngữ nghĩa ở mức nông

Its initial **Board of Visitors** included **U.S.**  
Presidents Thomas Jefferson, James Madison,  
and James Monroe.

1. Thomas Jefferson Is\_Member\_Of **Board of Visitors**
2. Thomas Jefferson Is\_President\_Of **U.S.**

# Suy diễn logic

- Phân tích ngữ nghĩa mức sâu

Its initial **Board of Visitors** included **U.S.** Presidents Thomas Jefferson, James Madison, and James Monroe.

$\exists x (Is\_Person(x) \ \& \ Is\_President\_Of(x, 'U.S.') \ \& \ Is\_Member\_Of(x, 'Board \ of \ Visitors'))$

# Biểu diễn từ và văn bản



# Biểu diễn từ như thế nào?

- WordNet: một từ điển chứa danh sách các từ đồng nghĩa (synonym sets) và bao hàm nghĩa (hypernyms)

*e.g. synonym sets containing "good":*

```
from nltk.corpus import wordnet as wn
poses = { 'n': 'noun', 'v': 'verb', 's': 'adj (s)', 'a': 'adj', 'r': 'adv' }
for synset in wn.synsets("good"):
    print("{}: {}".format(poses[synset.pos()],
        ", ".join([l.name() for l in synset.lemmas()])))
```

```
noun: good
noun: good, goodness
noun: good, goodness
noun: commodity, trade_good, good
adj: good
adj (sat): full, good
adj: good
adj (sat): estimable, good, honorable, respectable
adj (sat): beneficial, good
adj (sat): good
adj (sat): good, just, upright
...
adverb: well, good
adverb: thoroughly, soundly, good
```

*e.g. hypernyms of "panda":*

```
from nltk.corpus import wordnet as wn
panda = wn.synset("panda.n.01")
hyper = lambda s: s.hypernyms()
list(panda.closure(hyper))
```

```
[Synset('procyonid.n.01'),
Synset('carnivore.n.01'),
Synset('placental.n.01'),
Synset('mammal.n.01'),
Synset('vertebrate.n.01'),
Synset('chordate.n.01'),
Synset('animal.n.01'),
Synset('organism.n.01'),
Synset('living_thing.n.01'),
Synset('whole.n.02'),
Synset('object.n.01'),
Synset('physical_entity.n.01'),
Synset('entity.n.01')]
```

# Nhược điểm WordNet

- Thiếu sắc thái
  - Ví dụ “hy sinh” đồng nghĩa với “chết”
- Thiếu nghĩa các từ mới
  - Các từ mới về công nghệ, ngôn ngữ teen...
- Phụ thuộc suy nghĩ chủ quan của người làm
- Cần sức lao động lớn để tạo ra và chỉnh sửa
- Không thể tính độ tương đồng giữa hai từ

# Biểu diễn one-hot

- Biểu diễn từ như các ký hiệu rời rạc
- Độ dài vector bằng số từ trong từ điển

motel = [0 0 0 0 0 0 0 0 0 0 0 1 0 0 0 0]

hotel = [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0 0]

# Vấn đề của biểu diễn one-hot

- Người dùng tìm kiếm “Hanoi hotel”, ta cũng sẽ muốn hiển thị các kết quả của “Hanoi motel”
- Nhưng hai từ này biểu diễn trực giao, độ tương đồng bằng 0!

motel = [0 0 0 0 0 0 0 0 0 0 1 0 0 0 0]

hotel = [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0]

- **Giải pháp:**
  - Dựa vào WordNet? nhưng WordNet không hoàn thiện và nhiều nhược điểm...
  - **Học để mã hóa sự tương đồng trong các biểu diễn véc tơ**

# Vấn đề của biểu diễn one-hot

- Biểu diễn quá dài
- Với ngôn ngữ hàng ngày khoảng 20K từ, dịch máy 50K từ, khoa học vật liệu 500K từ, google web crawl 13M từ

motel = [0 0 0 0 0 0 0 0 0 0 0 1 0 0 0 0]  
hotel = [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0 0]

# Biểu diễn từ bằng ngữ cảnh của nó



- Ngữ nghĩa phân tán: Ý nghĩa một từ được quyết định bởi các từ thường xuất hiện gần nó

**“You shall know a word by the company it keeps”**

**(J. R. Firth 1957: 11)**

- Khi một từ xuất hiện trong văn bản, ngữ cảnh của nó là tập hợp các từ xuất hiện bên cạnh (trong một cửa sổ có kích thước cố định)
- Dùng nhiều ngữ cảnh khác nhau của một từ để xây dựng ý nghĩa của nó

*...government debt problems turning into **banking** crises as happened in 2009...*

*...saying that Europe needs unified **banking** regulation to replace the hodgepodge...*

*...India has just given its **banking** system a shot in the arm...*

# Word vector

- Mỗi từ được biểu diễn bởi một véc-tơ dày (dense) sao cho véc-tơ này tương tự với các véc-tơ biểu diễn các từ khác mà thường xuất hiện trong các ngữ cảnh tương tự
- Word vectors còn được gọi là word embeddings hay word representations

*banking* =

$$\begin{pmatrix} 0.286 \\ 0.792 \\ -0.177 \\ -0.107 \\ 0.109 \\ -0.542 \\ 0.349 \\ 0.271 \end{pmatrix}$$

# Word vector

*expect* =

$$\begin{pmatrix} 0.286 \\ 0.792 \\ -0.177 \\ -0.107 \\ 0.109 \\ -0.542 \\ 0.349 \\ 0.271 \\ 0.487 \end{pmatrix}$$



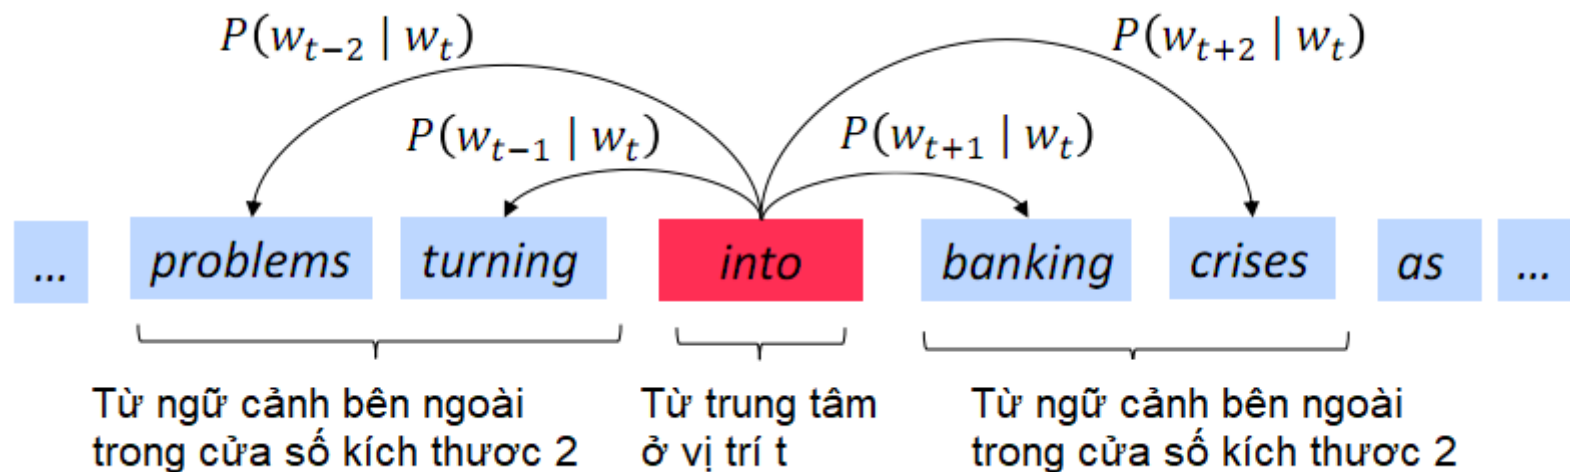


# Word2vec

- Word2vec (Mikolov et al. 2013) là phương pháp để học biểu diễn từ
- **Ý tưởng:**
  - Sử dụng một tập lớn nhiều văn bản (corpus)
  - Mỗi từ trong tập từ vựng cố định được biểu diễn bằng một véctơ
  - Duyệt từng vị trí  $t$  trong văn bản, mỗi vị trí chứa từ trung tâm  $c$  và các từ ngữ cảnh bên ngoài  $o$
  - Sử dụng độ tương đồng của các véc-tơ biểu diễn  $c$  và  $o$  để tính xác suất xuất hiện  $o$  khi có  $c$  (hoặc ngược lại)
  - Tinh chỉnh word véctơ để cực đại hóa xác suất này

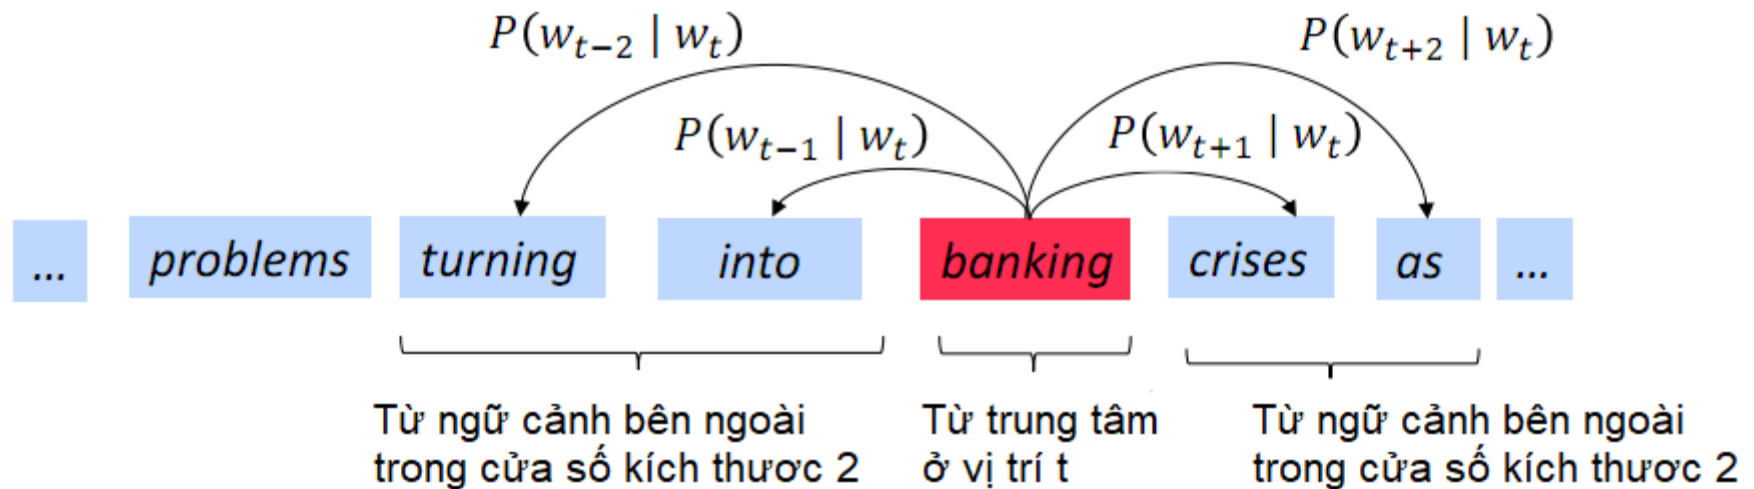
# Word2vec

- Ví dụ tính  $P(w_{t+j} | w_t)$  trong cửa sổ kích thước 2



# Word2vec

- Ví dụ tính  $P(w_{t+j} | w_t)$  trong cửa sổ kích thước 2



# Word2vec: Hàm mục tiêu

- Likelihood:

$$\text{Likelihood} = L(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w_{t+j} | w_t; \theta)$$

- Hàm mục tiêu:

$$J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

# Word2vec

- Làm sao để tính  $P(w_{t+j} | w_t; \theta)$  ?
- Ta sẽ dùng hai véctơ cho mỗi từ  $w$ :
  - $v_w$  khi  $w$  là từ trung tâm
  - $u_w$  khi  $w$  là từ ngữ cảnh ngoài
- Khi đó với từ trung tâm  $c$  và từ ngữ cảnh ngoài  $o$  ta có:

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$


# Word2vec

- Tham số mô hình:

$$\theta = \begin{bmatrix} v_{aardvark} \\ v_a \\ \vdots \\ v_{zebra} \\ u_{aardvark} \\ u_a \\ \vdots \\ u_{zebra} \end{bmatrix} \in \mathbb{R}^{2dV}$$


- Huấn luyện bằng SGD:

$$\theta^{new} = \theta^{old} - \alpha \nabla_{\theta} J(\theta)$$



# Word2vec: The skip-gram model

- Kích thước từ điển:  $V$
- Lớp input: mã hóa one-hot của từ trung tâm.
- Hàng thứ  $k$  của ma trận  $W_{V \times N}$  là véc tơ trung tâm biểu diễn từ thứ  $k$ .
- Cột thứ  $k$  của ma trận  $W'_{N \times V}$  là véc tơ ngữ cảnh của từ thứ  $k$  trong  $V$ . Chú ý mỗi từ được biểu diễn bởi 2 véc tơ, cả hai đều khởi tạo ngẫu nhiên.



# Word2vec: The skip-gram model

Source Text	Training Samples
<div> <div>The</div> <div>quick</div> <div>brown</div> <div>fox jumps over the lazy dog.</div> </div>	<div> <div>(the, quick)</div> <div>(the, brown)</div> </div>
<div> <div>The</div> <div>quick</div> <div>brown</div> <div>fox</div> <div>jumps over the lazy dog.</div> </div>	<div> <div>(quick, the)</div> <div>(quick, brown)</div> <div>(quick, fox)</div> </div>
<div> <div>The</div> <div>quick</div> <div>brown</div> <div>fox</div> <div>jumps</div> <div>over the lazy dog.</div> </div>	<div> <div>(brown, the)</div> <div>(brown, quick)</div> <div>(brown, fox)</div> <div>(brown, jumps)</div> </div>
<div> <div>The</div> <div>quick</div> <div>brown</div> <div>fox</div> <div>jumps</div> <div>over</div> <div>the lazy dog.</div> </div>	<div> <div>(fox, quick)</div> <div>(fox, brown)</div> <div>(fox, jumps)</div> <div>(fox, over)</div> </div>



# Word2vec: The skip-gram model

- Vấn đề: Mẫu số tính toán rất lâu!

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$


- Sử dụng negative sampling:

$$J(\theta) = \frac{1}{T} \sum_{t=1}^T J_t(\theta)$$


$$J_t(\theta) = \log \sigma(u_o^T v_c) + \sum_{i=1}^k \mathbb{E}_{j \sim P(w)} [\log \sigma(-u_j^T v_c)]$$

- $p(w) = U(w)^{3/4} / Z$ , trong đó  $U(w)$  là phân bố 1-gram.


# Một số kết quả word2vec



Male-Female




Verb tense




Country-Capital

# Một số kết quả word2vec




# Một số kết quả word2vec



# Word2vec: Continuous BOW

- Dùng các từ ngữ cảnh để đoán từ trung tâm



# Window based co-occurrence matrix



- Kích thước cửa sổ 1 (thường 5-10)
- Đối xứng (không phân biệt trái phải)
- Ví dụ corpus:
  - I like deep learning.
  - I like NLP.
  - I enjoy flying.

# Ma trận đồng xuất hiện dựa trên cửa sổ (co-occurrence matrix)



- Kích thước cửa sổ 1 (thường 5-10)
- Đối xứng (không phân biệt trái phải)
- Ví dụ corpus:
  - I like deep learning.
  - I like NLP.
  - I enjoy flying.

counts	I	like	enjoy	deep	learning	NLP	flying	.
I	0	2	1	0	0	0	0	0
like	2	0	0	1	0	1	0	0
enjoy	1	0	0	0	0	0	1	0
deep	0	1	0	0	1	0	0	0
learning	0	0	0	1	0	0	0	1
NLP	0	1	0	0	0	0	0	1
flying	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0

# Vấn đề ma trận đồng xuất hiện

- Kích thước tăng khi số từ tăng
- Số chiều cao, đòi hỏi nhiều bộ nhớ lưu trữ
- **Giải pháp:**
  - Giảm chiều
  - Thường 25-1000 chiều (tương đương word2vec)

$$\begin{array}{c}
 \boxed{\mathbf{A}_{m \times n}} = \boxed{\mathbf{U}_{m \times m}} \times \boxed{\Sigma_{m \times n}} \times \boxed{\mathbf{V}_{n \times n}^T} \\
 (m < n)
 \end{array}$$

$$\begin{array}{c}
 \boxed{\mathbf{A}_{m \times n}} = \boxed{\mathbf{U}_{m \times m}} \times \boxed{\Sigma_{m \times n}} \times \boxed{\mathbf{V}_{n \times n}^T} \\
 (m > n)
 \end{array}$$




# GloVe

- Kết hợp word2vec và ma trận đồng xuất hiện:

$$J = \sum_{i,j=1}^V f(X_{ij}) (w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$$

- Huấn luyện nhanh
- Có thể mở rộng cho corpus lớn
- Hiệu năng tốt ngay cả với corpus nhỏ và véc tơ bé



# Thư viện Xử lý NNTN và một số mô hình huấn luyện sẵn

# Gensim

- Cài đặt: `pip install gensim`

```
from gensim.models.word2vec import Word2Vec
from multiprocessing import cpu_count
import gensim.downloader as api
```

```
# Download dataset
```

```
dataset = api.load("text8")
data = [d for d in dataset]
```

```
# Split the data into 2 parts. Part 2 will be used later to update the model
```

```
data_part1 = data[:1000]
data_part2 = data[1000:]
```

```
# Train Word2Vec model. Defaults result vector size = 100
```

```
model = Word2Vec(data_part1, min_count = 0, workers=cpu_count())
```

```
# Get the word vector for given word
```

```
model['topic']
#> array([ 0.0512,  0.2555,  0.9393, ..., -0.5669,  0.6737], dtype=float32)
```

# Gensim



```
model.most_similar('topic')
#> [('discussion', 0.7590423822402954),
#>  ('consensus', 0.7253159284591675),
#>  ('discussions', 0.7252693176269531),
#>  ('interpretation', 0.7196053266525269),
#>  ('viewpoint', 0.7053568959236145),
#>  ('speculation', 0.7021505832672119),
#>  ('discourse', 0.7001898884773254),
#>  ('opinions', 0.6993060111999512),
#>  ('focus', 0.6959210634231567),
#>  ('scholarly', 0.6884037256240845)]
```

*# Save and Load Model*

```
model.save('newmodel')
model = Word2Vec.load('newmodel')
```

*# Update the model with new data.*

```
model.build_vocab(data_part2, update=True)
model.train(data_part2, total_examples=model.corpus_count, epochs=model.iter)
model['topic']
# array([-0.6482, -0.5468,  1.0688,  0.82  , ... , -0.8411,  0.3974], dtype=float32)
```

# Gensim

- Sử dụng pretrained từ Gensim

```
import gensim.downloader as api

# Download the models
fasttext_model300 = api.load('fasttext-wiki-news-subwords-300')
word2vec_model300 = api.load('word2vec-google-news-300')
glove_model300 = api.load('glove-wiki-gigaword-300')

# Get word embeddings
word2vec_model300.most_similar('support')
# [('supporting', 0.6251285076141357),
#  ...
#  ('backing', 0.6007589101791382),
#  ('supports', 0.5269277691841125),
#  ('assistance', 0.520713746547699),
#  ('supportive', 0.5110025405883789)]
```

# Một số pretrained

## BERT:

- Github: <https://github.com/google-research/bert>
- Bài báo: [Bidirectional Encoder Representations from Transformers](#)

## XLNet:

- Github: <https://github.com/zihangdai/xlnet>
- Bài báo: [XLNet: Generalized Autoregressive Pretraining for Language Understanding](#)

# Tài liệu tham khảo

1. Khóa cs244n của Stanford:

<https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1194/>